UNIVERSIDAD AUTONÓMA DEL ESTADO DE MÉXICO
Centro Universitario UAEM Nezahualcóyotl

Carrera:

Ingeniería en Sistemas Inteligentes

Título Del Proyecto:

Identificación de Niveles de Estrés Mediante Análisis de Patrones de Frecuencia Cardiaca

Profesor: Víctor Antonio flores lezama

EQUIPO:
Gongora García Thania Itzel
Reyes Rosales Jazmín
Sánchez Pérez Jesús

ISI TURNO: MATUTINO

SEMESTRE noveno

GRUPO “S9”

índice

Introducción....3
Contenido....4
Ui (interfaz de usuario)....5
Herramientas y materiales....8
Repositorio (Github ejem)....9
Estado del arte....10
Desarrollo de su software o App....12
Big data (si no lo tiene especifique que uso)....13
Capturas beta....14
UX(Experiencia del usuario)....15
Referencias biográficas....16
Resumen del proyecto....17

Introducción

Actualmente el estrés es un factor recurrente en la sociedad, que se define como la tensión física y emocional que se produce como respuesta a una presión externa o interna (Leal Beltran, 2006). Esta respuesta biológica surge ante diferentes situaciones o amenazas que permiten la autorregulación para actuar rápidamente ante estas situaciones.

Aunque es un factor favorable cuando se mantiene en un umbral normal que permite la correcta toma de decisiones (Cerda Molina, 2023), si se excede o no se controla puede producir problemas de salud.

Esta situación puede analizarse mediante el reconocimiento de patrones, el cual consiste en identificar características presentes en un conjunto de datos, en este caso, el análisis de las características que son afectadas por el estrés puede permitir clasificar los diferentes tipos de niveles de estrés.

Por esta razón, en el siguiente proyecto se pretende implementar un sistema que permite el reconocimiento de los diferentes niveles de estrés, tomando en cuenta principalmente el patrón de Frecuencia Cardiaca (FV) el cual es uno de los indicadores más relevantes que presenta variaciones provocadas por el aumento del estrés (López, 2015).

En entre otros patrones que se tomaran en cuenta para una clasificación correcta, son la edad, las horas de sueño, actividades, entre otros elementos que permitirán la correcta elección del nivel de estrés. Este modelo se pretende entrenar con un conjunto de datos aplicados al algoritmo de Random Forest, modelo que permite diferentes tipos de variables y la creación árboles para encontrar la mejor clasificación de los datos.

Contenido

En esta sección se describen los elementos tecnológicos, las herramientas de desarrollo y los procedimientos que se utilizarán para implementar el sistema de identificación de niveles de estrés mediante el análisis de patrones de frecuencia cardiaca. El proyecto integra componentes de hardware y software para obtener información fisiológica, procesarla mediante técnicas de reconocimiento de patrones y generar una clasificación estimada del nivel de estrés de una persona.

El sistema se desarrollará utilizando Python como lenguaje principal, Flask como framework para la comunicación entre la interfaz web y el servidor, y diferentes librerías especializadas en la adquisición, manipulación y análisis de datos. Asimismo, se empleará el algoritmo de aprendizaje automático Random Forest, debido a su capacidad para trabajar con distintas variables y establecer relaciones entre las características de entrada y las categorías de clasificación.

El funcionamiento general del sistema contempla el ingreso de información personal y contextual, la conexión con un sensor de frecuencia cardiaca mediante Bluetooth, la recopilación de datos fisiológicos, el procesamiento de las mediciones y la generación de un resultado en la interfaz del usuario. De esta manera, se busca construir una herramienta computacional que permita explorar la relación entre las características cardiacas y los niveles de estrés.

Para el desarrollo de este proyecto se utilizará el lenguaje de programación Python para el backend y para la implementación del frontend html, JavaScript y css. Las librerías que se agregarán para su implementación serán las siguientes: Dijango

- **Librería bleak:** Es una librería que permite manejar conexiones Bluetooth. Permite escanear, conectar y recibir datos en tiempo real, en este caso, se utilizará para obtener la frecuencia cardiaca de la banda que analiza a cada una de las personas.

- **Librería numpy:** Es una librería que permite el manejo de datos numéricos y operaciones matemáticas**.** Se utilizará para procesar los datos que lleguen del sensor, almacenar los intervalos de los latidos.

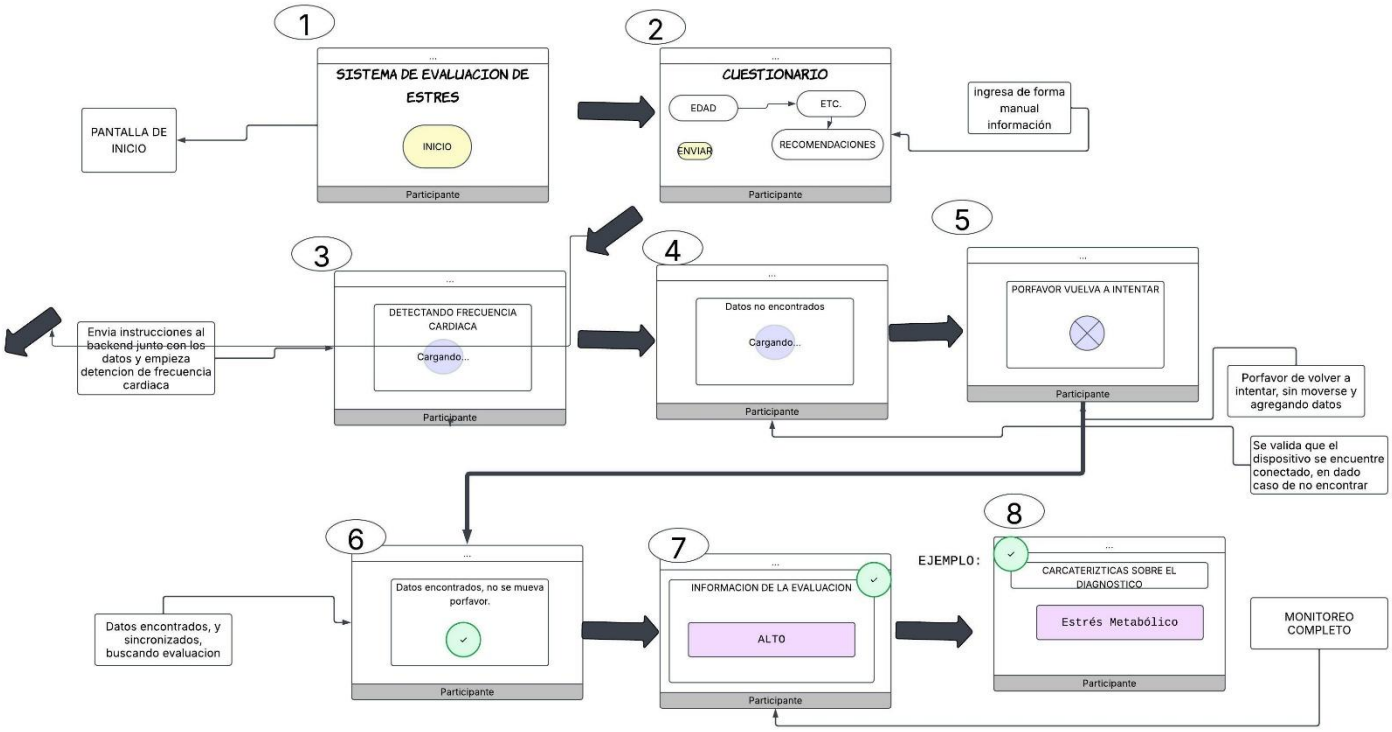
- **Librería hrv-analysis:** Es una librería que permite el análisis de la variabilidad de la frecuencia cardiaca, además de calcular automáticamente métricas de clínicas como el RMSSD (medida de cuanto varía el tiempo entre latidos consecutivos del corazón) o el SDNN (medida de la variabilidad del ritmo cardíaco que refleja la variación total entre latidos normales), que son indicadores de estrés.

- **Librería scikit-learn:** Es una librería que permite entrenar modelos de manchine Learning, como modelos predictivos. En este proyecto se usará para implementar el algoritmo Radom Forest.

- **Librería pandas:** Es una librería que permite la manipulación de datos, se usara para el análisis y limpieza de la base de datos que se evaluara en el algoritmo de Radom Forest

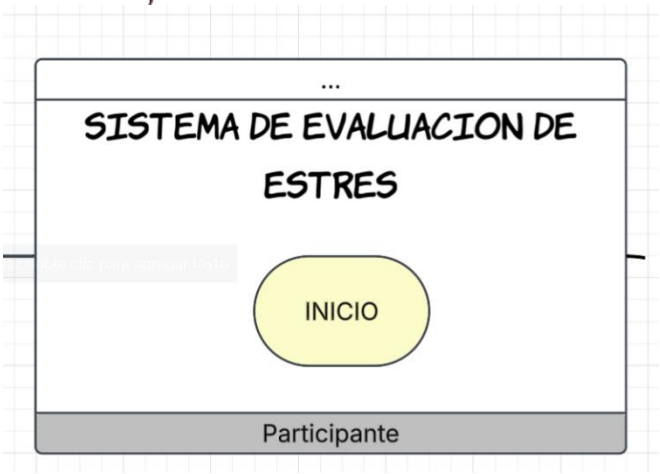
- **Librería joblib:** Es una librería utilizada para guardar y cargar modelos de machine learning de forma eficiente. Se utilizará para almacenar el modelo Random Forest ya entrenado en un archivo. pkl.

Ui (interfaz de usuario)

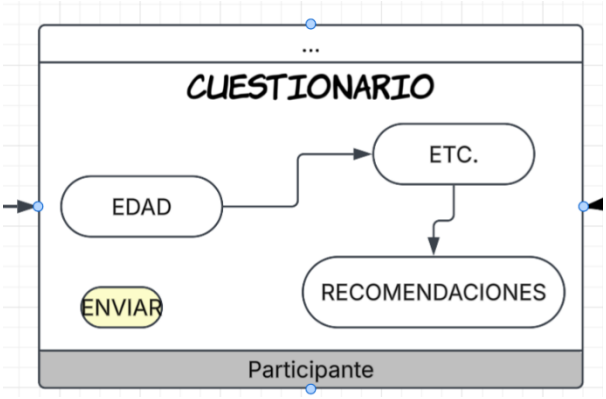


El diagrama, tiene como representación la forma y el proceso de automatización de Sistema de Evaluación de Estrés, la cual ayuda a combinar y a clasificar los datos en tiempo real del diagnostico.
Fases:

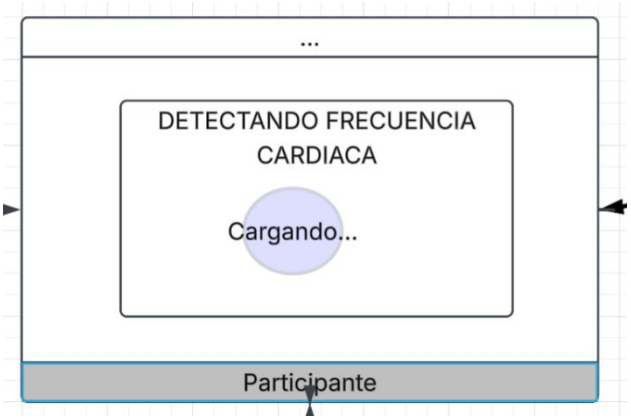
1. Inicio del sistema
2. Llenado de datos en el formulario
3. Comienza la detección de datos
4. Datos no encontrados
5. Intentar de nuevo, con recomendaciones
6. Datos encontrados, comienza la clasificación del diagnostico.
7. Te da la información de la evaluación
8. Características del diagnostico



Pantalla 1. Inicializa [INICIO] comienza el proceso de poder evaluar al usuario, así como también recopilación de dato o cualquier otra información.



Pantalla 2. Contiene un cuestionario sobre información vital para tener dar la evaluación del paciente, y algunas recomendaciones sobre como tener la postura para poder tener evaluación completa y más acertada.

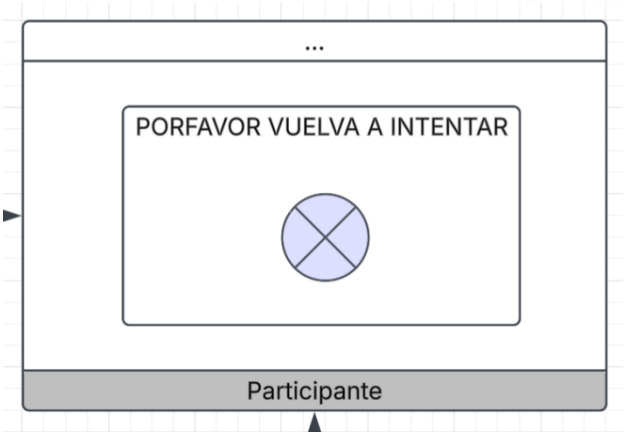


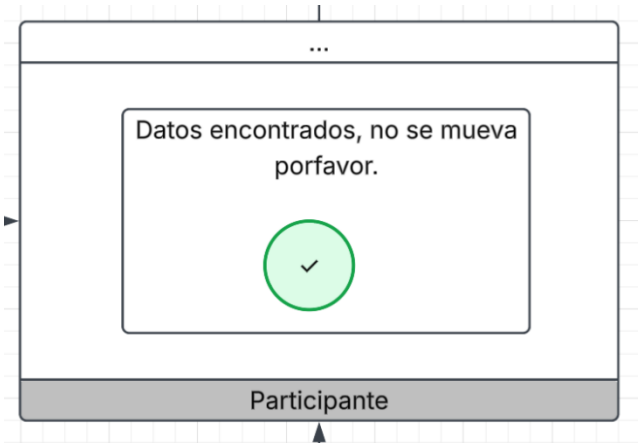
Pantalla 3. Empieza a detectar la frecuencia cardiaca, así como también tiene que guardar una postura correcta para mejor evaluación, más acertada y continua.



Pantalla 4. Datos no encontrados, hay algún movimiento erróneos, así como postura, etc.
Sigue detectando, pero no está encontrando ningún dato, por favor no moverte y tener en cuenta las recomendaciones que se dio en un inicio.

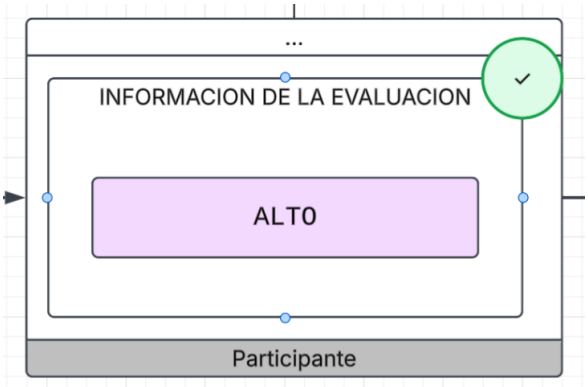
Pantalla 5. Error(⊗), no encontró ninguna información, así como también debe de volver a intentar, teniendo en cuenta las recomendaciones que se dan desde el principio para no volver a tener ningún error.

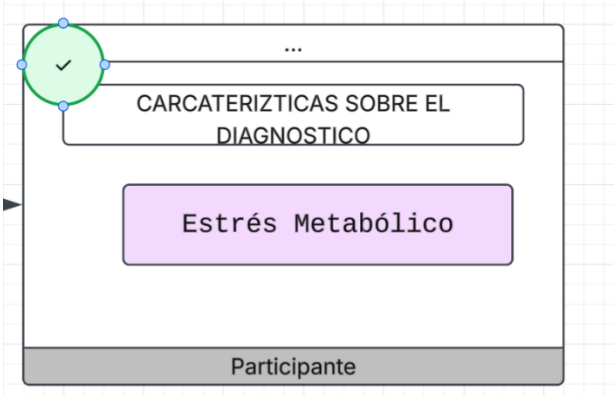




Pantalla 6 . (✓) Los datos son correctos pero aun debes de quedarte en la postura que estas ya que esta evaluando la información que esta encontrando.

Pantalla 7. Diagnostico completado, verificando que tengas un ritmo cardiaco "ALTO", así como también clasificando que tipo de diagnóstico especifico puede tener.





Pantalla 8. Logramos clasificar un tipo de diagnostico, teniendo en cuenta la información que se dio en el cuestionario y la frecuencia que se detectó en tiempo real, teniendo en cuenta que tienen un nivel de estrés, "Alto", con cada una de las características obtenemos un diagnostico de, "Estrés Metabólico".

Herramientas y materiales

En esta sección sé explican las diferentes herramientas que el sistema utilizará en su implementación para su desarrollo, así como los materiales.

Herramientas

Para el desarrollo del sistema se seleccionan las siguientes herramientas de hardware y software, explicadas a continuación:

Herramientas de Hardware

- **Sensor de Frecuencia Cardíaca H303:** Es una banda que mide la frecuencia cardiaca e implementa la transmisión de Bluetooth y permite la lectura de los intervalos R-R, que es un parámetro fisiológico para calcular la variabilidad de la frecuencia cardiaca.

- **Equipo de cómputo**: Es la base del sistema que debe contar con conectividad Bluetooth para enlazar el sensor y el sistema que implementa el modelo de maching learning

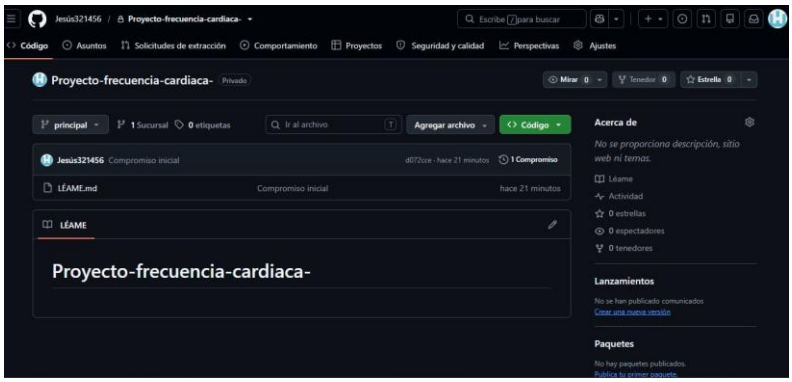
Herramientas de Software

- **Python**: Lenguaje principal en el que el sistema se desarrollara, donde se implementara el modelo de Radom Forest y la comunicación con el frontend

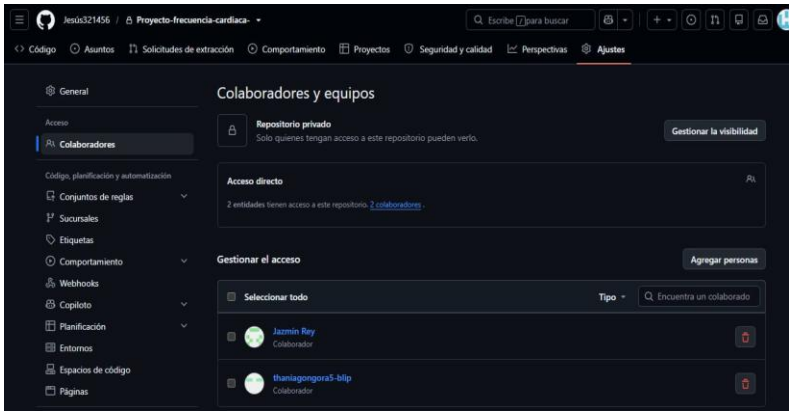
- **Flask**: Framework web de Python que actúa como el "Backend" del sistema. Recibe los datos clínicos ingresados en la pantalla, activa la recolección de datos por Bluetooth y devuelve el diagnóstico final de estrés.

Repositorio (GitHub ejem)

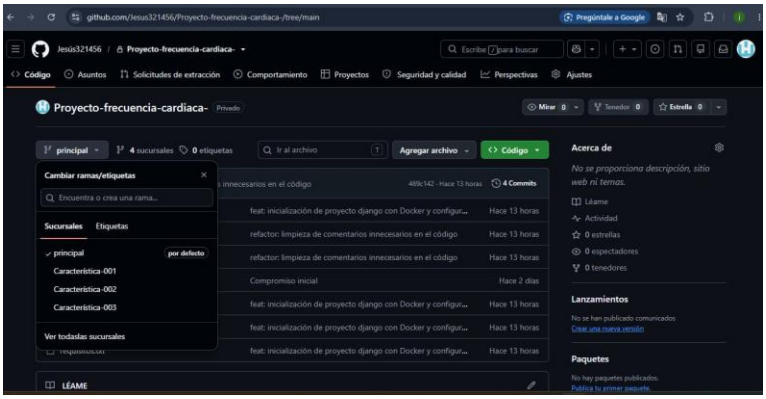
El código completo del proyecto está disponible en el siguiente repositorio:
🔗 https://github.com/Jesus321456/Proyecto-frecuencia-cardiaca-.git



Pantalla 1. Corresponde al proceso de creación del repositorio del proyecto, con el nombre, “Proyecto-frecuencia-cardiaca”



Pantalla 2. Agregamos a los colaboradores, siendo un equipo de tres, que se contiene de Full Stack, Backend, Fronend.



Pantalla 3. Agregamos la creación de ramas de trabajo independiente para cada integrante del equipo, dentro del repositorio del proyecto, con el propósito de que cada miembro pueda desarrollar actividades de manera organizad

Estado del arte

El reconocimiento de patrones se define como una ciencia que se ocupa del proceso de ingeniería, computación y matemáticas relacionada con objetos físicos, denominados patrones, con el fin de extraer información que permita establecer conjuntos para interpretar el mundo. (Carrasco-Ochoa y Martinez-Trinisdad). En la actualidad esta ciencia permite obtener diferentes investigaciones sobre patrones relacionados al estrés, algunos trabajos encontrados son los siguientes:

Detección de estrés por medio de redes neuronales artificiales en personal sanitario

Cañedo Figueroa, Duque Alarcón y Tinoco Zamudio (2024) realizaron una investigación para detectar diferentes tipos de estrés en el personal sanitario mediante el uso de redes neuronales artificiales. Para desarrollar el sistema, aplicaron un cuestionario de 30 preguntas a 215 trabajadores del ISSSTE de Chihuahua, con el que obtuvieron información relacionada con el agotamiento laboral, la fatiga por compasión y el estrés traumático secundario. Después, utilizaron Python para entrenar tres redes neuronales y realizaron ajustes para mejorar su capacidad de clasificación. Los resultados mostraron que los modelos alcanzaron valores F1 de 85.3 % para agotamiento laboral, 67.5 % para fatiga por compasión y 89.3 % para estrés traumático secundario. Los autores también señalaron que contar con más datos podría ayudar a mejorar los resultados.

Este estudio se relaciona con nuestro proyecto porque demuestra que la inteligencia artificial puede ayudar a identificar diferentes manifestaciones del estrés a partir de datos recopilados de las personas. Aunque los investigadores utilizaron cuestionarios y nosotros analizaremos la frecuencia cardiaca, ambos proyectos buscan que un modelo aprenda a reconocer patrones y clasifique la información. Además, nos sirve como referencia para entrenar y evaluar nuestro modelo de reconocimiento de patrones.

Medición de estrés a partir de la frecuencia cardíaca y la respuesta galvánica de la piel

González Rivera y Jiménez Cruz (2016) realizaron una investigación para observar cómo cambia el cuerpo de una persona cuando se encuentra bajo estrés. Para ello, trabajaron con 16 participantes y registraron dos señales: la frecuencia cardiaca y la respuesta galvánica de la piel, que permite observar cambios relacionados con la actividad de las glándulas sudoríparas. Primero tomaron las mediciones de los participantes mientras estaban en reposo y después realizaron actividades diseñadas para provocar estrés, como ejercicios de cálculo mental. Posteriormente, procesaron las señales con MATLAB para eliminar el ruido y comparar los cambios entre ambas situaciones. Los resultados mostraron que, en promedio, la frecuencia cardiaca aumentó de 73.28 a 76.62 latidos por minuto durante el estrés. La respuesta galvánica de la piel también aumentó y presentó cambios más constantes entre los participantes, mientras que en algunas personas la frecuencia cardiaca disminuyó.

Este estudio tiene una relación muy cercana con nuestro proyecto porque también busca identificar el estrés mediante cambios en la frecuencia cardiaca. Nos ayuda a entender que no todas las personas reaccionan de la misma manera ante una situación estresante, por lo que no basta con observar una sola medición. Por esta razón, queremos analizar los datos cardiacos de los estudiantes y utilizar Random Forest para encontrar patrones que permitan estimar sus niveles de estrés, tomando en cuenta que los resultados pueden variar de una persona a otra.

Detección de Estrés Laboral mediante Dispositivos Wearables y HRV

Al-Shargabi et al. (2020) desarrollaron un sistema de monitoreo en tiempo real orientado a la identificación de estrés mental en entornos de trabajo. La investigación, realizada en Malasia, empleó bandas torácicas comerciales para capturar señales ECG y extraer variables clave en los dominios del tiempo y de la frecuencia (como la relación LF/HF y el parámetro SDNN). Mediante la implementación de un clasificador, alcanzaron una exactitud del 88.5% en la detección de tres niveles de estrés (bajo, moderado y alto). Los investigadores concluyeron que la técnica de ensamblaje por embolsado (bagging) inherente a Random Forest mitiga eficientemente los artefactos por movimiento y el ruido presente en los bioseñales capturados en entornos no controlados.

Clasificación Multimodal del Estrés Fisiológico

Schmidt et al. (2018) introdujeron el conjunto de datos de acceso público WESAD (Wearable Stress and Affect Detection), el cual se ha convertido en el estándar de referencia. En su estudio desarrollado en Alemania, los autores capturaron bioseñales fisiológicos (electrocardiografía, actividad electrodérmica y temperatura) utilizando dispositivos portátiles durante estados de estrés inducido y relajación. Para la clasificación de los estados emocionales y fisiológicos, aplicaron múltiples algoritmos de aprendizaje automático, entre los cuales el modelo obtuvo una precisión superior al 92% en la discriminación de niveles de estrés frente a estados neutros. Los autores destacaron que las características derivadas de la variabilidad cardíaca, como la desviación cuadrática media de diferencias sucesivas (RMSSD) y la potencia en la banda de baja frecuencia (LF), mostraron el mayor peso discriminativo dentro del modelo.

Comparativa de Algoritmos de Aprendizaje Automático en Bioseñales Cardíacas

Pramukantoro y Gofur (2021) evaluaron el rendimiento de diversos modelos de aprendizaje automático (incluyendo Máquinas de Vectores de Soporte, Árboles de Decisión) para la estimación de niveles de estrés a partir de características de la HRV extraídas de sensores ópticos (PPG). El estudio, llevado a cabo en Indonesia, demostró que superó a los clasificadores individuales al reducir el sobreajuste (overfitting) y manejar adecuadamente la no linealidad de los datos cardíacos, alcanzando una precisión promedio del 90.3%. Además, la investigación subrayó la importancia de utilizar técnicas de selección e importancia de características (feature importance) para reducir la dimensionalidad de las métricas de HRV sin perder capacidad predictiva.

Diseño e implementación de un sistema para la detección del estrés mediante redes neuronales convolucionales a partir de imágenes térmicas

En este trabajo, David Sandoval Rodríguez-Bermejo desarrolló un sistema para detectar el estrés de manera no invasiva utilizando imágenes térmicas del rostro y redes neuronales convolucionales. Para realizarlo, primero investigó sobre el estrés, la termografía aplicada a la medicina y el funcionamiento de las redes neuronales. Después, diseñó un procedimiento para obtener imágenes térmicas, preparó los datos para entrenar los modelos de aprendizaje automático y evaluó diferentes redes neuronales. Como resultado, consiguió un sistema capaz de identificar el nivel de estrés a partir de imágenes térmicas con una precisión del 96 %

Este trabajo se relaciona con nuestro proyecto porque demuestra cómo las técnicas de reconocimiento de patrones y el aprendizaje automático pueden utilizarse para identificar niveles de estrés a partir de datos fisiológicos. Aunque el estudio utiliza imágenes térmicas del rostro, nuestro proyecto busca analizar patrones de frecuencia cardiaca mediante un sensor y emplear un modelo de Random Forest para identificar posibles niveles de estrés. Ambos trabajos tienen el mismo propósito general: utilizar información medible y técnicas computacionales para apoyar la detección del estrés.

Desarrollo de su software o App

Problemáticas:

- Obteniendo las instrucciones tuvimos debate en el tema a desarrollar, teniendo en cuenta cada una de las instrucciones, así como también cada una de las características que se necesita
- Error en GitHub, teniendo en cuenta que no teníamos el conocimiento como tal, empezando a investigar cada uno de los pasos para armar las ramas de cada uno de los integrantes
- Error en pantallas, para poder cargar cada uno de los diagnósticos ya que era complicado tener en cuneta cada una de las características para dar el diagnostico.
- Problemas para poder obtener la rama de cada uno de los integrantes en GitHub
- Conexión a la base de datos, teniendo en cuenta todas las entidades.
- Problemas para poder jalar cualquier cambio de cada uno de los integrantes, ya que realizábamos cualquier cambio, así como también teníamos errores para poder tener el proyecto completo
- Error para verificar que tenemos la rama completada
- Poder subir los cambios de cada uno es error, ya que tenemos en cuenta que para hacer cada uno de los cambios tendremos que subir las actualizaciones
- Verificación de internet para nuestros dispositivos para poder subir cualquier cambio, así como también la lentitud del dispositivo de alguno de mis compañeros.
- Problema para entrar, ya que los correos son correctos, pero Git, tuvo problemas para verificar o encontrarlos
- Error al no guardar los cambios, ya que se borrar al serrar o no guardar cualquier movimiento que hacemos.

Big data (si no lo tiene especifique que uso)

Para el desarrollo del proyecto se emplea un procesamiento de un conjunto de datos para el entrenamiento y validación del modelo predictivo, en este caso para el entrenamiento del modelo de Random Forest

Se utiliza un dataset obtenido del repositorio público Kaggle. Este conjunto de datos proporciona un historial de diferentes personas, que contiene métricas fisiológicas y hábitos de estilo de vida con los respectivos diagnósticos de sus niveles de estrés. Para optimizar el rendimiento del sistema y la experiencia del usuario, el dataset fue depurado, seleccionando exclusivamente las variables que el modelo evaluará.

Entre las variables dividas en categorías, se eligen son las siguientes:

Variables de Perfil: Corresponden a los datos demográficos y de salud a largo plazo del paciente.

- Edad (Age)
- Género (Gender)
- Ocupación (Occupation)
- Categoría de IMC (BMI Category)
- Trastorno del sueño (Sleep Disorder)

Variables de Estilo de Vida: Factores que pueden variar diariamente y alteran la respuesta fisiológica.

- Duración del sueño (Sleep Duration)
- Calidad del sueño (Quality of Sleep)
- Nivel de actividad física (Physical Activity Level)

Variables Biométricas: Datos obtenidos y procesados directamente por la conexión con el dispositivo hardware.

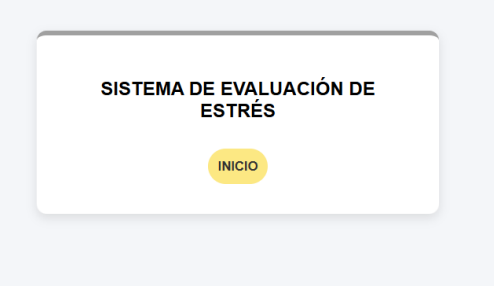
- Frecuencia Cardíaca Promedio (Heart Rate)
- Variabilidad de la Frecuencia Cardíaca (RMSSD)

Variable Objetivo: Es la clase que el algoritmo aprende a predecir a partir de las variables anteriores.

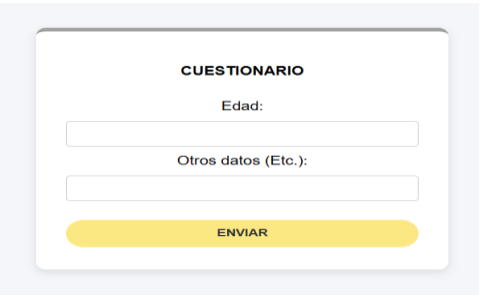
- Nivel de estrés (Stress Level).

Capturas beta

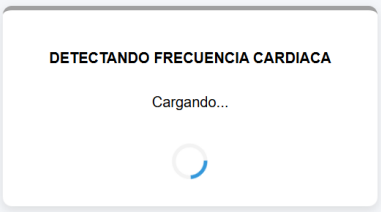
Pantalla 1. Inicializa el programa obteniendo el inicio de el formullario que se tiene que llenar con los datos del paciente para poder tener un diagnostico mas acertado.



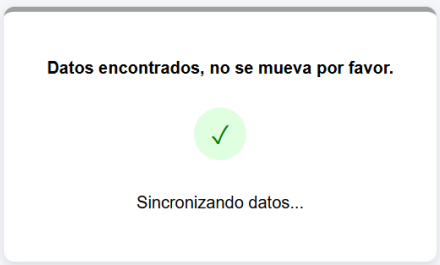
Pantalla 2. Vemos el formulario, tenemos que llenar algunos datos, serviran para poder tener mas precision y poder ayudar a ser mas acertados.



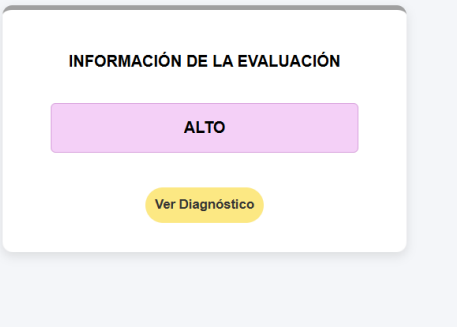
Pantalla 3. Empieza a cragar, con ello empieza a detectar la frecuencia cardiaca del usuario.



Pantalla 4. Los datos estan cargados, quiere decir que encontro la frecuencia cardica correctamente, con ello empieza a sincronizar la frecuencia cardica con la informacion que esta proporcionada en el formulario.



Pantalla5. Termina la sincronizacion y da la informacion mas acertada, gracias a los datos, teniendo un resultado de estrés, “alto”



UX(Experiencia del usuario)

Referencias biográficas

Cerda-Molina, A. L., Mayagoitia-Novales, L., y Borráz-León, J. I. (2023). El estrés: un balance entre la supervivencia y el deterioro en la salud. Elementos, (132). https://elementos.buap.mx/directus/storage/uploads/00000008964.pdf

Leal Beltrán, I. Y. (2006). El estrés: Cómo nos afecta. Revista Científica General José María Córdova, 4(4), 56-58. https://www.redalyc.org/pdf/4762/476259067015.pdf

Al-Shargabi, A. A., Procházka, A., & Vyšata, O. (2020). Mental stress detection using heart rate variability and machine learning algorithms. Sensors, 20(11), Article 3215. https://doi.org/10.3390/s20113215

Pramukantoro, E. S., & Gofur, A. (2021). Heart rate variability-based stress level detection using Random Forest classifier. Journal of Computer Science and Information Technology, 9(2), 112–120. https://doi.org/10.21512/jcsit.v9i2.7100

Schmidt, P., Reiss, A., Duerichen, R., Marberger, C., & Van Laerhoven, K. (2018). Introducing WESAD: A multimodal dataset for wearable stress and affect detection. In Proceedings of the 20th ACM International Conference on Multimodal Interaction (pp. 400–408). Association for Computing Machinery. https://doi.org/10.1145/3242969.3242985

Sandoval Rodríguez-Bermejo, D. (2019). Diseño e implementación de un sistema para la detección del estrés mediante redes neuronales convolucionales a partir de imágenes térmicas [Trabajo de Fin de Máster, Universidad Politécnica de Madrid]. Archivo Digital UPM. https://oa.upm.es/57804/

Cañedo Figueroa, C. E., Duque Alarcón, X., & Tinoco Zamudio, M. T. S. (2024). Detección de estrés por medio de redes neuronales artificiales en personal sanitario. TECNOCIENCIA Chihuahua, 18(3), e1641. https://doi.org/10.54167/tch.v18i3.1641

González Rivera, M. A., & Jiménez Cruz, J. R. (2016). Medición de estrés a partir de la frecuencia cardíaca y la respuesta galvánica de la piel. Pistas Educativas, (120).

Resumen del proyecto

El proyecto consiste en desarrollar un sistema capaz de identificar diferentes niveles de estrés mediante el análisis de patrones cardíacos y el uso de técnicas de reconocimiento de patrones y aprendizaje automático. La idea principal es analizar los cambios que se presentan en la actividad cardíaca de una persona para identificar características que puedan estar relacionadas con situaciones de estrés. Para ello, se recopilarán datos de la frecuencia cardíaca y de los intervalos de tiempo entre latidos consecutivos, con los cuales se calculará la variabilidad de la frecuencia cardíaca (HRV), una variable que permite estudiar las variaciones en el ritmo cardíaco.

Para llevar a cabo el sistema, se utilizará una banda o dispositivo capaz de obtener las mediciones cardíacas y transmitir los datos para su procesamiento. Posteriormente, se empleará Python para organizar la información, calcular las características necesarias y preparar los datos que utilizará el modelo de aprendizaje automático. Se contempla utilizar el algoritmo Random Forest, que permitirá analizar los patrones identificados y clasificar las mediciones en diferentes niveles de estrés. Para que el modelo pueda realizar estas clasificaciones, será necesario contar con datos previamente etiquetados que permitan entrenarlo y evaluar su funcionamiento.

Además, se considerarán algunos factores que pueden influir en las mediciones, como la actividad física reciente, el consumo de cafeína y las horas de descanso, debido a que estos pueden provocar cambios en la frecuencia cardíaca sin que necesariamente exista estrés. También se desarrollará una interfaz web que permita iniciar las mediciones, mostrar los resultados y facilitar la interacción con el sistema.

El backend se encargará de gestionar la comunicación entre la interfaz, los datos obtenidos y el modelo de clasificación.
Finalmente, se realizarán pruebas para evaluar el funcionamiento del sistema y determinar qué tan bien identifica los patrones asociados con los diferentes niveles de estrés.

Para ello, se utilizarán métricas de evaluación que permitan analizar el desempeño del modelo y detectar posibles errores en las clasificaciones. Como resultado, se espera obtener un prototipo funcional con fines académicos y experimentales, capaz de analizar patrones cardíacos y generar una estimación del nivel de estrés.

Es importante considerar que la frecuencia cardíaca puede verse afectada por diversos factores, por lo que el resultado será una estimación y no un diagnóstico médico.